

# Esame di Probabilità e Statistica [3231]

## Esame di Calcolo delle Probabilità e Statistica [2959]

Corso di Studi di Ingegneria Gestionale (D.M.270/04) (L)

Dipartimento di Meccanica, Matematica e Management  
Politecnico di Bari

Cognome: \_\_\_\_\_

Nome: \_\_\_\_\_

Matricola: \_\_\_\_\_

Docente: Gianluca Orlando

Appello: luglio 2023 - turno II

Data: 20/07/2023

Tempo massimo: 2 ore.

---

**Esercizio 1.** (6 punti) I seguenti dati mettono in relazione il numero di unità di un bene che sono state ordinate in funzione del prezzo del bene in sei diverse località:

numero ordini	88	112	123	136	158	172
prezzo	50	40	35	30	20	14

1. Rappresentare i dati in uno scatterplot.
2. Determinare (derivando le formule) la retta di regressione lineare e rappresentarla.
3. Determinare il coefficiente di correlazione lineare.

**Soluzione. Soluzione.** 1. Segue lo scatterplot (con la retta di regressione lineare):




Figura 1: Scatterplot e retta di regressione lineare.

2. Denotiamo con  $(x_1, y_1), \dots, (x_n, y_n)$ ,  $n = 6$ , i dati del campione. Cerchiamo la retta di equazione

$$y = ax + b$$

che meglio approssima i dati, utilizzando il metodo dei minimi quadrati. Vogliamo minimizzare l'errore

$$r(a, b) = \sum_{i=1}^n (y_i - ax_i - b)^2.$$

Imponiamo che il gradiente rispetto ad  $(a, b)$  sia nullo, ovvero,

$$\begin{aligned} 0 = \partial_a r(a, b) &= -2 \sum_{i=1}^n (y_i - ax_i - b)x_i = -2 \sum_{i=1}^n (x_i y_i - ax_i^2 - bx_i), \\ 0 = \partial_b r(a, b) &= -2 \sum_{i=1}^n (y_i - ax_i - b) \end{aligned}$$

Dalla seconda equazione segue che

$$nb = \sum_{i=1}^n (y_i - ax_i) \implies b = \bar{y} - a\bar{x}.$$

Sostituendo nella prima,

$$\begin{aligned} \sum_{i=1}^n (x_i y_i - ax_i^2 - bx_i) = 0 &\implies \sum_{i=1}^n (x_i y_i - ax_i^2 - x_i \bar{y} + a\bar{x} x_i) = 0 \\ &\implies a \left( \sum_{i=1}^n x_i^2 - n\bar{x}^2 \right) = \sum_{i=1}^n x_i y_i - n\bar{x} \bar{y} \\ &\implies a = \frac{\sum_{i=1}^n x_i y_i - n\bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}. \end{aligned}$$

Completiamo la tabella con i valori necessari a calcolare  $a$  e  $b$ :

							somma
$x_i$	88	112	123	136	158	172	789
$y_i$	50	40	35	30	20	14	189
$x_i^2$	7744	12544	15129	18496	24964	29584	108461
$y_i^2$	2500	1600	1225	900	400	196	6821
$x_i y_i$	4400	4480	4305	4080	3160	2408	22833

Pertanto  $\bar{x} = 789/6 = 131.5$  e  $\bar{y} = 189/6 = 31.5$ . Segue che

$$\begin{aligned} a &= \frac{22833 - 6 \cdot 131.5 \cdot 31.5}{108461 - 6 \cdot 131.5^2} = \frac{-2020.5}{4707.5} \simeq -0.43, \\ b &= 31.5 + 0.43 \cdot 131.5 \simeq 88.05, \end{aligned}$$

ovvero, la retta di regressione lineare ha equazione

$$y = -0.43x + 88.05.$$

3. Per calcolare il coefficiente di correlazione lineare usiamo la formula

$$\begin{aligned} \rho_{x,y} &= \frac{\sum_{i=1}^n x_i y_i - n\bar{x} \bar{y}}{\sqrt{\sum_{i=1}^n x_i^2 - n\bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n\bar{y}^2}} = \frac{22833 - 6 \cdot 131.5 \cdot 31.5}{\sqrt{108461 - 6 \cdot 131.5^2} \sqrt{6821 - 6 \cdot 31.5^2}} \\ &= \frac{-2020.5}{\sqrt{4707.5} \sqrt{867.5}} \simeq -0.9998. \end{aligned}$$

**Esercizio 2.** (7 punti) La prova scritta di un esame molto difficile è costituita da 4 esercizi. Uno studente si reca all'esame senza aver studiato, sperando di copiare. La probabilità di riuscire a copiare bene un singolo esercizio dipende da quanto è stanco il professore.

- Se il professore è poco stanco, la probabilità di copiare bene un singolo esercizio è del 2%.
- Se il professore è molto stanco, la probabilità di copiare bene un singolo esercizio è del 5%.
- Il professore è molto stanco con il 20% di probabilità.

Si assuma che la copia di un esercizio non influenzi la copia di un altro esercizio. Lo studente supera la prova se riesce a copiare bene almeno 2 esercizi.

1. Il professore annuncia all'inizio della prova: "Oggi sono molto stanco!". Con che probabilità lo studente supera la prova?
2. Il professore non dice nulla all'inizio della prova e non sappiamo se è poco stanco o molto stanco. Finisce l'esame e lo studente supera la prova! Con che probabilità il professore era molto stanco?

**Soluzione.** Consideriamo le variabili aleatorie

$$X = \text{"numero di esercizi copiati bene"}$$

e poiché dobbiamo contare il numero di successi in 4 prove indipendenti (la copia di un esercizio non influenza la copia di un altro esercizio)

$$Y = \text{"numero di esercizi copiati bene se il professore è poco stanco"} \sim B(4, 2\%)$$

$$Z = \text{"numero di esercizi copiati bene se il professore è molto stanco"} \sim B(4, 5\%).$$

Ricordiamo che per una binomiale  $B(n, p)$ , la probabilità di assumere il valore  $k$  è  $\binom{n}{k} p^k (1-p)^{n-k}$ . Inoltre, introduciamo

$$W \sim \text{Be}(20\%),$$

dove  $W = 1$  se il professore è molto stanco e  $W = 0$  se il professore è poco stanco.

Dalle ipotesi del problema,

$$\mathbb{P}(\{X = k\} | \{W = 0\}) = \mathbb{P}(\{Y = k\}),$$

$$\mathbb{P}(\{X = k\} | \{W = 1\}) = \mathbb{P}(\{Z = k\}).$$

1. Sappiamo che si è realizzato l'evento  $\{W = 1\}$ . Allora dobbiamo calcolare

$$\begin{aligned} \mathbb{P}(\{X \geq 2\} | \{W = 1\}) &= \mathbb{P}(\{Z \geq 2\}) = \mathbb{P}(\{Z = 2\}) + \mathbb{P}(\{Z = 3\}) + \mathbb{P}(\{Z = 4\}) \\ &= \binom{4}{2} (5\%)^2 (95\%)^2 + \binom{4}{3} (5\%)^3 (95\%)^1 + \binom{4}{4} (5\%)^4 (95\%)^0 \\ &= 1.40\%. \end{aligned}$$

2. Sappiamo che lo studente ha superato la prova, cioè si è realizzato l'evento  $\{X \geq 2\}$ . Calcoliamo allora

$$\begin{aligned} \mathbb{P}(\{W = 1\} | \{X \geq 2\}) &= \frac{\mathbb{P}(\{W = 1\} \cap \{X \geq 2\})}{\mathbb{P}(\{X \geq 2\})} \\ &= \frac{\mathbb{P}(\{X \geq 2\} | \{W = 1\}) \mathbb{P}(\{W = 1\})}{\mathbb{P}(\{X \geq 2\} | \{W = 1\}) \mathbb{P}(\{W = 1\}) + \mathbb{P}(\{X \geq 2\} | \{W = 0\}) \mathbb{P}(\{W = 0\})} \\ &= \frac{\mathbb{P}(\{X \geq 2\} | \{W = 1\}) \mathbb{P}(\{W = 1\})}{\mathbb{P}(\{X \geq 2\} | \{W = 1\}) \mathbb{P}(\{W = 1\}) + \mathbb{P}(\{X \geq 2\} | \{W = 0\}) \mathbb{P}(\{W = 0\})} \\ &= \frac{\mathbb{P}(\{Z \geq 2\}) \mathbb{P}(\{W = 1\})}{\mathbb{P}(\{Z \geq 2\}) \mathbb{P}(\{W = 1\}) + \mathbb{P}(\{Y \geq 2\}) \mathbb{P}(\{W = 0\})} \\ &= \frac{1.40\% \cdot 20\%}{1.40\% \cdot 20\% + 0.23\% \cdot 80\%} \simeq 60.34\%, \end{aligned}$$

dove abbiamo usato che

$$\begin{aligned}\mathbb{P}(\{Y \geq 2\}) &= \mathbb{P}(\{Y = 2\}) + \mathbb{P}(\{Y = 3\}) + \mathbb{P}(\{Y = 4\}) \\ &= \binom{4}{2}(2\%)^2(98\%)^2 + \binom{4}{3}(2\%)^3(98\%)^1 + \binom{4}{4}(2\%)^4(98\%)^0 \\ &= 0.23\%.\end{aligned}$$

---

**Esercizio 3.** (8 punti) Devi viaggiare su un treno che percorre il seguente tragitto:

$$A \rightarrow B \rightarrow C.$$

Assumiamo che:

- nella tratta  $A \rightarrow B$  il treno accumuli un ritardo medio di 2 min e che questo ritardo sia distribuito con legge esponenziale;
- nella tratta  $B \rightarrow C$  il treno accumuli un ritardo medio di 2 min e che questo ritardo sia distribuito con legge esponenziale;
- il ritardo accumulato nella tratta  $A \rightarrow B$  e il ritardo accumulato nella tratta  $B \rightarrow C$  siano indipendenti.

Rispondere ai seguenti quesiti:

1. Qual è la probabilità che nella tratta  $A \rightarrow B$  il treno accumuli un ritardo compreso tra 4 min e 12 min?
2. In media, qual è il ritardo accumulato nell'intero viaggio  $A \rightarrow B \rightarrow C$ ? Motivare la risposta.
3. Qual è la varianza del ritardo accumulato nell'intero viaggio  $A \rightarrow B \rightarrow C$ ? Motivare la risposta.
4. Considerare la probabilità che il ritardo accumulato nell'intero viaggio  $A \rightarrow B \rightarrow C$  sia maggiore di 10 min. Stabilire se questa probabilità è maggiore o minore di 5%.

**Soluzione.** Consideriamo le due variabili aleatorie

$$X_1 = \text{"ritardo accumulato nella tratta } A \rightarrow B" \sim \text{Exp}(\lambda),$$

$$X_2 = \text{"ritardo accumulato nella tratta } B \rightarrow C" \sim \text{Exp}(\lambda).$$

In entrambi i casi si ha che  $\mathbb{E}(X_1) = \mathbb{E}(X_2) = \frac{1}{\lambda} = 2$  quindi  $\lambda = \frac{1}{2}$ .

Ricordiamo che la densità di una legge esponenziale con parametro  $\lambda$  è  $\lambda e^{-\lambda x}$ .

1. Viene chiesto di calcolare

$$\begin{aligned}\mathbb{P}(\{4 \leq X_1 \leq 12\}) &= \int_4^{12} \lambda e^{-\lambda x} dx = \left[ -e^{-\lambda x} \right]_4^{12} \\ &= e^{-10\lambda} - e^{-30\lambda} = e^{-\frac{4}{2}} - e^{-\frac{12}{2}} = e^{-2} - e^{-6} \simeq 13.29\%.\end{aligned}$$

2. Il ritardo accumulato nell'intero viaggio è  $X_1 + X_2$ . Per la linearità del valore atteso si ha che  $\mathbb{E}(X_1 + X_2) = \mathbb{E}(X_1) + \mathbb{E}(X_2) = \frac{1}{\lambda} + \frac{1}{\lambda} = \frac{2}{\lambda} = 4$ .

3. Poiché  $X_1$  e  $X_2$  sono indipendenti, si ha che

$$\text{Var}(X_1 + X_2) = \text{Var}(X_1) + \text{Var}(X_2) = \frac{1}{\lambda^2} + \frac{1}{\lambda^2} = \frac{2}{\lambda^2} = 2 \cdot 4 = 8.$$

4. Dobbiamo calcolare

$$\mathbb{P}(\{X_1 + X_2 \geq 10\}).$$

Occorre ricordare che la somma di esponenziali indipendenti è distribuita come una legge Gamma, ovvero  $X_1 + X_2 \sim \text{Gamma}(2, \lambda)$ , che ha densità

$$\frac{\lambda^2}{\Gamma(2)} x e^{-\lambda x} = \lambda^2 x e^{-\lambda x},$$

dove abbiamo usato il fatto che

$$\Gamma(n) = (n-1)\Gamma(n-1) \implies \Gamma(2) = 1 \cdot \Gamma(1) = 1.$$

Quindi, integrando per parti,

$$\begin{aligned} \mathbb{P}(\{X_1 + X_2 \geq 10\}) &= \int_{10}^{+\infty} \lambda^2 x e^{-\lambda x} dx = \left[ -\lambda x e^{-\lambda x} \right]_{10}^{+\infty} + \int_{10}^{+\infty} \lambda e^{-\lambda x} dx \\ &= 10\lambda e^{-10\lambda} + e^{-10\lambda} = (10\lambda + 1)e^{-10\lambda} = (10/2 + 1)e^{-5} = 6e^{-5} \simeq 4\%, \end{aligned}$$

quindi è minore del 5%.

In alternativa, si può ricordare che  $\Gamma(\frac{n}{2}, \frac{1}{2}) = \chi^2(n)$ , quindi  $\Gamma(2, \frac{1}{2}) = \chi^2(4)$ . Utilizzando la tavola della chi-quadro troviamo che una  $Q_4 \sim \chi^2(4)$  soddisfa

$$\mathbb{P}(\{Q_4 > 9.488\}) = 5\%,$$

quindi la probabilità di essere maggiore di 10 è più piccola del 5%.

---

**Esercizio 4.** (7 punti) Un'auto è pubblicizzata come avente un consumo medio di benzina inferiore a 4.3  $\ell/100\text{km}$  (litri per 100 km) nella guida in autostrada. Si misura il consumo in un campione e si ottengono i seguenti dati ( $\ell/100\text{km}$ ):

3.4	3.3	5.5	5.0	3.2	3.9	3.8	4.1	5.3	5.3
3.7	5.7	5.5	5.6	5.7	5.1	4.9	4.5	3.1	5.6
3.1	4.8	5.5	5.1	6.4	3.5	5.6	6.4	4.4	4.6
4.8	3.8	4.2	5.4	3.0	4.2	5.7	6.0	4.3	4.4

La media calcolata sul campione risulta essere 4.7  $\ell/100\text{km}$ . Si sa che la deviazione standard dei consumi è 1.0  $\ell/100\text{km}$ .

1. I dati sono significativi al 10% per non credere alla pubblicità?
2. Assumiamo che la pubblicità dica il vero. Vengono misurati i dati di campioni della stessa ampiezza di quello precedente tante volte e ogni volta viene effettuato un test come nel punto 1. In media, dopo quanti tentativi osserveremo dei dati significativi al 10% che non ci fanno credere alla pubblicità?

**Soluzione.** 1. Abbiamo una popolazione  $X: \Omega \rightarrow \mathbb{R}$  (non necessariamente normale) con  $\mathbb{E}(X) = \mu$  e  $\text{Var}(X) = \sigma^2$  e un campione casuale  $X_1, \dots, X_n$  estratto dalla popolazione con  $n = 40 \geq 30$ . La varianza  $\sigma^2 = 1$  è nota. Dobbiamo impostare il seguente test di ipotesi

$$H_0: \mu \leq \mu_0, \quad H_1: \mu > \mu_0,$$

con livello di significatività  $\alpha = 10\%$ , dove  $\mu_0 = 4.3$ .

Poiché l'ipotesi alternativa è  $H_1: \mu > \mu_0$ , i dati saranno significativi se la media è sufficientemente più grande di  $\mu_0$ . La regione critica è allora della forma

$$R_c = \{(x_1, \dots, x_n) \in R(X_1, \dots, X_n) : \bar{x}_n > \mu_0 + \delta\},$$

dove  $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$  è la media calcolata sulla realizzazione  $x_1, \dots, x_n$  del campione casuale.

Assumiamo l'ipotesi nulla  $H_0$  vera, cioè  $\mu \leq \mu_0$ .

Se  $\mu \leq \mu_0$ , non è detto che  $\mathbb{E}(X_i) = \mu_0$ . Il valore della media della popolazione è  $\mu$ , quindi  $\mathbb{E}(X_i) = \mu$ . Tuttavia, poiché  $\mu \leq \mu_0$

$$\bar{X}_n > \mu_0 + \delta \implies \bar{X}_n > \mu + \delta.$$

Utilizziamo questo per il calcolo della regione critica.

Utilizzando la media campionaria  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ,

$$\begin{aligned} \mathbb{P}(\{(X_1, \dots, X_n) \in R_c\}) &= \mathbb{P}(\{\bar{X}_n > \mu_0 + \delta\}) \leq \mathbb{P}(\{\bar{X}_n > \mu + \delta\}) \\ &= \mathbb{P}\left(\left\{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} > \frac{\delta}{\sigma/\sqrt{n}}\right\}\right), \end{aligned}$$

Non conosciamo la distribuzione della popolazione, ma il campione è numeroso ( $n \geq 30$ ). Per il Teorema del Limite Centrale, si ha che  $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{n \rightarrow +\infty} Z$  in legge, dove  $Z \sim \mathcal{N}(0, 1)$ . Quindi

$$\mathbb{P}\left(\left\{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} > \frac{\delta}{\sigma/\sqrt{n}}\right\}\right) \simeq \mathbb{P}\left(\left\{Z > \frac{\delta}{\sigma/\sqrt{n}}\right\}\right).$$

Introduciamo il valore  $z_\alpha$  tale che

$$\mathbb{P}(\{Z > z_\alpha\}) = \alpha.$$

Allora, scegliendo

$$\frac{\delta}{\sigma/\sqrt{n}} = z_\alpha \implies \delta = \frac{\sigma}{\sqrt{n}} z_\alpha,$$

otteniamo (approssimativamente)

$$\mathbb{P}(\{(X_1, \dots, X_n) \in R_c\}) \leq \alpha,$$

(ovvero la probabilità di commettere un errore del I tipo è approssimativamente più piccola di  $\alpha$ ).

In conclusione, la regione critica è

$$R_c = \left\{(x_1, \dots, x_n) \in R(X_1, \dots, X_n) : \bar{x}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha\right\},$$

e decidiamo come segue:

- Se  $\bar{x}_n > \mu_0 + \frac{\sigma}{\sqrt{n}} z_\alpha$ , i dati sono sufficientemente significativi da rifiutare  $H_0$ . L'ipotesi nulla  $H_0$  viene rifiutata (con livello di significatività  $\alpha$ ).

- Se  $\bar{x}_n \leq \mu_0 + \frac{\sigma}{\sqrt{n}}z_\alpha$ , i dati non sono sufficientemente significativi da rifiutare. L'ipotesi nulla  $H_0$  non viene rifiutata (con livello di significatività  $\alpha$ ).

Calcoliamo  $z_{0.1} \simeq 1.285$  utilizzando le tavole e quindi

$$\mu_0 + \frac{\sigma}{\sqrt{n}}z_\alpha = 4.4 + \frac{1}{\sqrt{40}}1.285 \simeq 4.6.$$

Poiché

$$\bar{x}_n = 4.7 > 4.6,$$

i dati sono significativi al 10% per rifiutare l'ipotesi nulla.

2. Consideriamo una legge geometrica  $Y \sim \text{Geo}(p)$  dove  $p$  è la probabilità di un successo, ovvero la probabilità di rifiutare l'ipotesi nulla quando questa è vera. Quindi  $p = \alpha = 10\%$ . Per la legge geometrica si sa che

$$\mathbb{E}(Y) = \frac{1}{p} = 10.$$